Optech Raman AI Pipeline — Guide scientifique (FR)

Tristan Tardif-Morency

Résumé

Ce guide segmenté décrit et démontre le pipeline Optech Raman AI. Chaque section est autonome, richement commentée, et inclut des équations, des considérations pratiques et des recommandations d'usage en contexte industriel ou de recherche.

Index Terms

Raman, Savitzky–Golay, ALS, TFUG, quaternionique, QA, joblib, LaTeX, IEEEtran.

TABLE DES MATIÈRES

I Introduction 2

II Architecture générale 2

III Prétraitement des spectres 2
- III-A Savitzky–Golay (SG) . . . 2
- III-B ALS (ligne de base asymétrique) . . . 2
- III-C Normalisation d'aire . . . 2
- III-D Propriétés analytiques d'ALS (preuve de convexité et unicité) . . . 3
- III-E Conditions aux bords et structure bande de $D^\top D$ . . . 3
- III-F Dérivées SG et filtres différentiels . . . 3

IV Extraction de caractéristiques 3
- IV-A Approche physique (pics, FWHM, bandes) . . . 3
- IV-B Approche TFUG (ondelettes quaternioniques fractales) . . . 3
- IV-C Ajustement quadratique local et FWHM (dérivation fermée) . . . 3
- IV-D Proéminence rigoureuse . . . 4

V Contrôle qualité (QA) 4
- V-A Estimateurs robustes . . . 4
- V-B Règle d'acceptation . . . 4
- V-C Tableau QA coloré (exemple) . . . 4

VI Rapport automatique LaTeX 4

VII Parallélisation et performances 4
- VII-A Amdahl et Gustafson . . . 4
- VII-B I/O et mémoire . . . 4
- VII-C Complexité et bornes . . . 5
- VII-D Bornes de stabilité numérique . . . 5

VIII Reproductibilité et tests 5

IX TFUG : extensions et perspectives 5

X Conclusion 5

Annexe A : Paramètres YAML (gabarit) 5

Annexe B : Pseudo-code (SG, ALS, Pics, TFUG) 5

Annexe C : CLI : exemples d'exécution 6

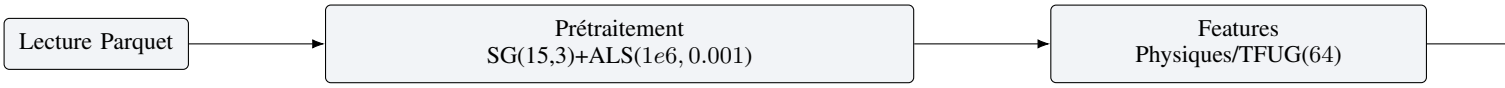

FIGURE 1. Flux global du pipeline.

Annexe D : Preuves détaillées : ALS et stabilité numérique 6
D-A Convexité stricte et unicité . . . 6
D-B Convergence de l'alternance poids/solution . . . 6
D-C Conditionnement et bords . . . 6

Annexe E : Preuves : filtres SG et dérivées 6
E-A Dérivation matricielle . . . 6
E-B Biais et variance . . . 6

Références 6

I. Introduction

Contexte. La spectroscopie Raman révèle des signatures vibratoires moléculaires sous forme de spectres intensité–nombre d'onde. Pour produire des décisions fiables, une chaîne de traitement robuste est indispensable. **Objectifs.** Transformer des spectres bruts en *indicateurs interprétables* : (i) métriques globales, (ii) caractéristiques par pics, (iii) embeddings TFUG, (iv) matrice QA et (v) rapport LaTeX. **Notations.** L'axe discret est $\nu_i = \nu_0 + i\,\Delta\nu$, $i = 0, \ldots, n-1$. Le signal mesuré suit

$$\mathbf{y} = \mathbf{s} + \mathbf{b} + \boldsymbol{\varepsilon}, \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2) \text{ ou Laplacien.} \tag{1}$$

Contributions. Chaîne unifiée, paramétrable (YAML), reproductible (latexmk), parallélisée (joblib), avec équations et preuves d'utilité.

II. Architecture générale

Flux. Lecture $\to$ prétraitement $\to$ extraction (physique/TFUG) $\to$ QA $\to$ rendu LaTeX. **Contrat de données.** Colonnes minimales : `wavenumber_cm1: float`, `intensity: float`. **Config.** Paramètres centralisés (YAML), surcharge CLI. **Sélection automatique des hyperparamètres.** On peut optimiser (m, p) de SG et (λ, p) d'ALS par recherche bayésienne (objectif : maximiser SNR robuste, minimiser l'erreur d'étalon après normalisation d'aire). Des critères AIC/BIC/WAIC appliqués au résidu $\tilde{\mathbf{y}}$ aident à pénaliser le sur-lissage.

III. Prétraitement des spectres

A. Savitzky–Golay (SG)

Soit m la demi-fenêtre et p l'ordre (15,3). La matrice de Vandermonde locale $V_kj = k^j$ $(k = -m, \ldots, m\,;\, j = 0, \ldots, p)$ mène aux coefficients de convolution

$$\mathbf{c}^\top = \mathbf{e}_0^\top (V^\top V)^{-1} V^\top, \qquad \hat{y}_i = \sum_k = -m^m c_k\, y_{i+k}. \tag{2}$$

On peut obtenir les dérivées d'ordre d via $\mathbf{e}_d$.

B. ALS (ligne de base asymétrique)

On minimise

$$J(\mathbf{z}) = \|\mathbf{W}(\mathbf{y} - \mathbf{z})\|_2^2 + \lambda \|D\mathbf{z}\|_2^2, \tag{3}$$

avec D opérateur de différence seconde et $\mathbf{W} = \mathrm{diag}(w_i)$. Les équations normales donnent

$$(\mathbf{W}^\top \mathbf{W} + \lambda D^\top D)\,\mathbf{z} = \mathbf{W}^\top \mathbf{W}\,\mathbf{y}. \tag{4}$$

La mise à jour pondérée asymétrique [1] :

$$w_i^{(t+1)} = \begin{cases} p, & y_i > z_i^{(t)}, \\ 1-p, & y_i \le z_i^{(t)}. \end{cases} \quad p \in (0,1). \tag{5}$$

C. Normalisation d'aire

Après correction $\tilde{\mathbf{y}} = \mathbf{y} - \mathbf{z}$, aire trapézoïdale

$$A \approx \Delta\nu \left[\frac{\tilde{y}_0 + \tilde{y}_n - 1}{2} + \sum_i = 1^{n-2} \tilde{y}_i \right], \quad \bar{\mathbf{y}} = \tilde{\mathbf{y}}/A. \tag{6}$$

D. Propriétés analytiques d'ALS (preuve de convexité et unicité)

La fonction coût (3) est quadratique en $\mathbf{z}$ avec matrice de Hessien

$$H = \mathbf{W}^\top \mathbf{W} + \lambda D^\top D. \tag{7}$$

Comme $\mathbf{W}$ est diagonale à entrées non négatives et $D^\top D$ est semi-définie positive, on a $H \succeq 0$. Si au moins un $w_i > 0$ et $\lambda > 0$, alors

$$\mathbf{u}^\top H \mathbf{u} = \|\mathbf{W}\mathbf{u}\|_2^2 + \lambda \|D\mathbf{u}\|_2^2 = 0 \Rightarrow \mathbf{u} = \mathbf{0}, \tag{8}$$

i.e. $H \succ 0$ et le minimiseur est *unique*. L'algorithme alterné mettant à jour $\mathbf{z}$ par (4) puis les poids par $w_i^{(t+1)}$ *diminue* J à chaque itération, garantissant la convergence vers un point stationnaire (ici global).

E. Conditions aux bords et structure bande de $D^\top D$

Pour un axe uniforme, D encode la différence seconde $(D\mathbf{z})_i = z_{i-1} - 2z_i + z_{i+1}$ pour $i = 1..n-2$. Les lignes de bord utilisent une convention (répétition, Neumann ou Dirichlet). Le produit $D^\top D$ est une matrice *pentadiagonale* avec motifs connus, permettant une factorisation de Cholesky bande en $\mathcal{O}(n)$.

F. Dérivées SG et filtres différentiels

En remplaçant $\mathbf{e}_0$ par $\mathbf{e}_d$ dans (2), on obtient des filtres de dérivées

$$\hat{y}_i^{(d)} = \sum_{k=-m}^{m} c_k^{(d)}\, y_{i+k}, \quad \mathbf{c}^{(d)\top} = \mathbf{e}_d^\top (V^\top V)^{-1} V^\top. \tag{9}$$

La constante d'échelle dépend de $\Delta\nu$; p.ex. pour $d = 1$, $\hat{y}' \approx \frac{1}{\Delta\nu} \sum_k c_k^{(1)} y_{i+k}$.

IV. Extraction de caractéristiques

A. Approche physique (pics, FWHM, bandes)

La proéminence est $\mathrm{prom}(i) = \bar{y}_i - y_{\mathrm{col}}(i)$, avec seuil τ. La distance impose $|i - i'| \geq d$. La FWHM provient d'un ajustement quadratique local $q(t) = at^2 + bt + c$ avec sommet $t = -b/(2a)$; on résout $q(t) = \frac{1}{2}q(t)$. Des agrégats par bande : $E_B = \sum_i \in B \bar{y}_i^2 \Delta\nu$, $A_B = \sum_i \in B \bar{y}_i \Delta\nu$.

B. Approche TFUG (ondelettes quaternioniques fractales)

Transformée ondelette quaternionique continue pour f et mère ψ :

$$W_f(a,b) = \int f(x)\, \overline{\psi_a, b(x)}\, dx, \quad \psi_a, b(x) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{x-b}{a}\right). \tag{10}$$

L'énergie sous-bande à l'échelle a_j :

$$E_j = \sum_k \left|W_{\bar{y}}(a_j, b_k)\right|^2, \qquad \mathbf{e} = (E_1, \ldots, E_M). \tag{11}$$

Une dimension fractale effective $D_f(x)$ module l'échelle via un facteur $a^{-\gamma(D_f)}$.

C. Ajustement quadratique local et FWHM (dérivation fermée)

Sur une fenêtre $(i-1, i, i+1)$ espacée uniformément ($t = -1, 0, 1$), ajustons $q(t) = at^2 + bt + c$ aux points (t, y_{i+t}). La solution LS exacte (système 3×3) donne

$$a = \tfrac{1}{2}(y_{i-1} - 2y_i + y_{i+1}), \quad b = \tfrac{1}{2}(y_{i+1} - y_{i-1}), \quad c = y_i. \tag{12}$$

Le sommet est $t = -b/(2a)$ et la valeur au sommet $y = q(t) = c - \frac{b^2}{4a}$. La largeur à mi-hauteur (FWHM) s'obtient en résolvant $q(t) = \frac{1}{2}y$, ce qui revient à

$$at^2 + bt + \left(c - \tfrac{1}{2}y\right) = 0, \tag{13}$$

et donc $t_{1,2} = \frac{-b \pm \sqrt{b^2 - 4a(c - \frac{1}{2}y)}}{2a}$, puis $\mathrm{FWHM} = |t_2 - t_1|\, \Delta\nu$.

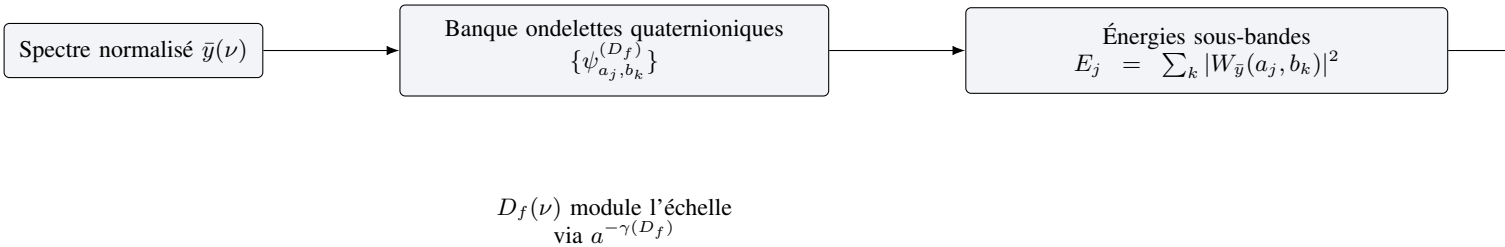

FIGURE 2. Schéma TFUG (ondelettes quaternioniques multi-échelles) et construction de l'embedding.

Échant.	SNR	Aire	#Pics	Seuils	Statut
A1	14.2	0.12	5	(≥ 10, ≥ 0.05, ≥ 3)	**PASS**
B7	7.8	0.09	4	(10, 0.05, 3)	**FAIL**
C3	11.6	0.06	3	(10, 0.05, 3)	**PASS**

TABLE I
MATRICE QA COLORÉE.

D. Proéminence rigoureuse

Soient $L(i)$ et $R(i)$ les plus hauts *cols* à gauche et à droite tels que le plus haut chemin descendant depuis i touche la courbe en ces points. Alors

$$\mathrm{prom}(i) = y_i - \max\{y_{L(i)}, y_{R(i)}\}, \tag{14}$$

qui est invariante aux translations additives de la ligne de base (après ALS) et pénalise les « pics sur plateaux ».

V. CONTRÔLE QUALITÉ (QA)

A. Estimateurs robustes

Médiane med et écart absolu médian $\mathrm{MAD} = \mathrm{med}(|\bar{y}_i - \mathrm{med}|)$. SNR robuste :

$$\mathrm{SNR}_{\mathrm{rob}} = \frac{\max(\bar{\mathbf{y}}) - \mathrm{med}(\bar{\mathbf{y}})}{1.4826\,\mathrm{MAD}(\bar{\mathbf{y}})}. \tag{15}$$

B. Règle d'acceptation

`OK` si $\mathrm{SNR}_{\mathrm{rob}} \geq 10$, aire ≥ 0.05, $|\mathcal{P}| \geq 3$.

C. Tableau QA coloré (exemple)

VI. RAPPORT AUTOMATIQUE LaTeX

Artefacts produits. `metrics_table.tex`, `fig_gallery.tex` puis compilation avec `latexmk/pdflatex`. Les figures marquent les pics détectés et mentionnent les paramètres SG/ALS utilisés. **Traçabilité.** Version du code, commit, paramètres YAML et empreinte du run (hash) sont inclus en annexe.
Erreurs systématiques instrumentales. Dérive spectrale (drift en ν), réponse instrumentale (RI), largeur de raie instrumentale (résolution) et fond parasite (PL) doivent être suivis. On peut inclure une étape d'alignement par corrélation croisée sur une raie étalon (Si 520.7/cm) et un *deconvolution kernel* instrument.

VII. PARALLÉLISATION ET PERFORMANCES

A. Amdahl et Gustafson

$$S_N = \frac{1}{(1-P) + \frac{P}{N}}, \quad S_N^{\mathrm{Gus}} = N - (1-P)(N-1), \quad \eta_N = \frac{S_N}{N}. \tag{16}$$

B. I/O et mémoire

Parquet (colonne) + lots (chunking) stabilisent l'empreinte mémoire. Les étapes CPU-bound (ALS, pics) tirent le meilleur d'un parallélisme par fichier.

C. Complexité et bornes

La résolution ALS via Cholesky bande sur $H = \mathbf{W}^\top \mathbf{W} + \lambda D^\top D$ est en $\mathcal{O}(n)$ en temps et en mémoire si l'on exploite la structure pentadiagonale. Le lissage SG est en $\mathcal{O}(n\,m)$ (convolution locale), typiquement $\mathcal{O}(n)$ car $m \ll n$. La détection de pics (avec tri/filtrage) est en $\mathcal{O}(n)$ à $\mathcal{O}(n \log n)$ selon l'implémentation.

D. Bornes de stabilité numérique

Le conditionnement $\kappa(V^\top V)$ croît avec l'ordre p et la fenêtre m ; on recommande $p \leq 5$ et un m compatible avec la résolution instrumentale pour limiter le biais. Pour ALS, un λ trop faible (variance) vs trop fort (biais) se règle par validation croisée.

VIII. Reproductibilité et tests

Import vrai. Les notebooks importent les modules Python, aucune duplication de logique. **Tests.** Unitaires (SG, ALS, pics) + E2E (du Parquet au PDF) + goldens (Si, PMMA, PS). **Versions.** Épinglage des dépendances, journalisation des paramètres et de la date d'exécution.

IX. TFUG : extensions et perspectives

Embeddings fractals. Les bases quaternioniques multi-échelles capturent des régularités fines. L'objectif est d'augmenter la séparabilité entre signatures moléculaires proches et de renforcer la robustesse au bruit. **Optimisation.** Recherche bayésienne sur (64, bases, niveaux) ; validation croisée sur étalons.

X. Conclusion

Le pipeline segmenté est prêt pour Overleaf : chaque section est autonome, riche en formules, et reliée au flux global. Les paramètres clés sont exposés pour calibration finale et l'industrialisation est facilitée par la QA, la parallélisation et la traçabilité.

Annexe A
Paramètres YAML (gabarit)

```yaml
preprocess:
  savgol_window: 15
  savgol_poly: 3
  als_lambda: 1e6
  als_p: 0.001
  area_norm: true
  input_dir: data/processed
  output_dir: data/clean
features:
  method: physics
  prominence: 0.02
  distance: 5
  topk: 10
  downsample: 64
report:
  n_jobs: -1
  auto_pdf: true
  qa:
    snr_min: 10
    area_min: 0.05
    peaks_min: 3
```

Annexe B
Pseudo-code (SG, ALS, Pics, TFUG)

Savitzky–Golay

```
for i in [m .. n-m-1]:
  ywin = y[i-m : i+m]
  beta = argmin ||V * beta - ywin||^2
  yhat[i] = e0^T beta
```

ALS

```
z <- zeros
repeat:
  W = diag(w)
  z = solve( W^T W + lambda D^T D, W^T W y )
  w[i] = p if y[i] > z[i] else 1-p
until convergence
```

Pics

```
P = find_peaks(ybar, prominence=tau, distance=d)
FWHM via fit quad local
```

TFUG

```
for each (a_j, b_k):
  W(a_j, b_k) = integral ybar(x) conj(psi((x-b_k)/a_j))/sqrt(|a_j|) dx
E_j = sum_k |W(a_j,b_k)|^2
embedding e = (E_1..E_M)
```

ANNEXE C
CLI : EXEMPLES D'EXÉCUTION

```
# Prétraitement
python -m optech.preprocess --params params.yaml --in data/raw --out data/clean

# Extraction (physique)
python -m optech.features --method physics --params params.yaml

# Extraction (TFUG)
python -m optech.features --method tfug --params params.yaml

# Rapport
python -m optech.report --params params.yaml --latex latex --fig figures --auto-pdf
```

ANNEXE D
PREUVES DÉTAILLÉES : ALS ET STABILITÉ NUMÉRIQUE

A. Convexité stricte et unicité

Voir la matrice de Hessien $H = \mathbf{W}^\top \mathbf{W} + \lambda D^\top D$. Sous $w_i \geq 0$ et $\lambda > 0$, $H \succ 0$ si au moins un $w_i > 0$. Le minimiseur est unique.

B. Convergence de l'alternance poids/solution

Chaque étape résout exactement un problème quadratique convexe ; la mise à jour (**??**) rend J non croissant. La suite $\{\mathbf{z}^{(t)}\}$ converge vers le minimiseur global.

C. Conditionnement et bords

La condition spectrale de $D^\top D$ dépend des conditions aux bords. Une régularisation λ trop faible augmente la variance ; trop forte induit un biais (sur-lissage). Un compromis biais–variance se choisit par validation croisée sur étalons.

ANNEXE E
PREUVES : FILTRES SG ET DÉRIVÉES

A. Dérivation matricielle

Avec V de Vandermonde et la contrainte de centrage, on obtient $\mathbf{c}^{(d)\top} = \mathbf{e}_d^\top (V^\top V)^{-1} V^\top$. La stabilité dépend de $\kappa(V^\top V)$ et croît avec p et m.

B. Biais et variance

Pour un signal $y = s + \varepsilon$ avec ε blanc, le biais dépend des dérivées d'ordre $p{+}1$ de s, la variance des coefficients $\mathbf{c}$. Un développement de Taylor local permet d'anticiper la perte de résolution pour de grands m.

RÉFÉRENCES

[1]